

**Universidad Nacional Abierta y a Distancia  
Vicerrectoría Académica y de Investigación**

**Entorno: Métodos Cuantitativos en Investigación  
Código: 203538899**

**Momento # 1  
Ciclo de Gestión del Conocimiento No. 2**

**Fase 2. Análisis cuantitativo integral: de la exploración a las técnicas avanzadas**

**1. Descripción del Ciclo de Gestión de Conocimiento.**

**Tabla 1.** *Información del ciclo.*

| <b>Aspecto</b>                                           | <b>Descripción</b>                                        |
|----------------------------------------------------------|-----------------------------------------------------------|
| <b>1. Tipo:</b>                                          | Individual                                                |
| <b>2. Puntaje del Ciclo de Gestión de Conocimiento</b>   | <b>200</b>                                                |
| <b>3. Unidad gestora:</b>                                | Escuela de Ciencias Básicas Tecnología e Ingeniería ECBTI |
| <b>4. Programa doctoral:</b>                             | Doctorado en Tecnologías de Información — DTI             |
| <b>5. Inicia el:</b>                                     | lunes, 14 de septiembre de 2026                           |
| <b>6. Finaliza el:</b>                                   | domingo, 8 de noviembre de 2026                           |
| <b>7. Horas de trabajo independiente:</b>                | <b>48</b>                                                 |
| <b>8. Horas de acompañamiento docente:</b>               | <b>24</b>                                                 |
| <b>9. Unidades de Gestión de Conocimiento:</b>           | 3                                                         |
| <b>10. Unidades de Formación Avanzada – UFA</b>          | 2                                                         |
| <b>11. Unidades de Gestión de la Investigación – UGI</b> | 1                                                         |
| <b>12. Unidades de Gestión de la Innovación – UGIIn</b>  | 0                                                         |

## **2. Descripción detallada del Ciclo de gestión de conocimiento.**

Con este Ciclo de Gestión de Conocimiento se espera aportar al desarrollo del siguiente resultado de aprendizaje de programa:

**RAP 1** – Analizar conocimientos avanzados en la frontera del conocimiento en el contexto de la investigación en Tecnología de Información para la comprensión de aspectos teóricos y prácticos.

**RAP 2** – Evaluar teorías y metodologías científicas en el ámbito de la Tecnología de Información para la resolución de problemas.

**RAP 3** – Integrar conocimientos teóricos y prácticos avanzados para la resolución de problemas complejos en el ámbito de la investigación en Tecnología de Información.

### **El Ciclo de Gestión de Conocimiento consiste en:**

#### **Fase No. 2 – Análisis cuantitativo integral: de la exploración a las técnicas avanzadas**

Se entrega en el Momento 1: Aplicación y creación, recurso de Evaluación.

Este ciclo tiene como objetivo que el doctorando ejecute de principio a fin un análisis cuantitativo riguroso sobre un dataset real de Tecnología de Información, y produzca un reporte científico reproducible de calidad publicable. El ciclo está organizado en dos partes complementarias:

- Parte 1 — Análisis fundamental (Semanas 5–8): construye las competencias analíticas básicas que todo investigador cuantitativo en TI necesita, organizadas por la lógica de lo que el investigador hace con los datos — conocer, comparar, modelar, extender — en lugar de por temas estadísticos aislados. Cierra con un punto de control intermedio obligatorio.
- Parte 2 — Profundización avanzada (Semanas 9–12): el doctorando selecciona una técnica de un menú de cuatro opciones según la pertinencia para su línea de investigación del DTI, y la aplica al dataset. Cierra con code review entre pares y entrega final con publicación bajo principios FAIR.

Todos los estudiantes de la cohorte trabajan sobre el mismo dataset compartido, seleccionado y provisto por el tutor al inicio del ciclo con un problema analítico rector. Esto permite la comparación de decisiones analíticas entre compañeros, habilita la revisión científica entre pares con conocimiento real del contexto, y replica el proceso de revisión por pares de las revistas académicas. Todos los análisis se realizan en Python con Jupyter Notebooks, instaurando la replicabilidad científica como práctica central del entorno.

Dataset de la cohorte: el tutor provee a través del campus virtual un dataset real de TI con documentación completa (diccionario de variables, fuente, contexto de recolección) y un problema analítico rector que orienta los análisis sin prescribir los métodos. El dataset es único para toda la cohorte del período académico.

A continuación, se detalla cada paso del ciclo:

## **Parte 1 — Análisis Fundamental (Semanas 5–8)**

### **Semana 5 – Conocer los datos: exploración y estadística descriptiva (Trabajo individual)**

Objetivo:

Familiarizarse con el dataset compartido del DTI, ejecutar un análisis exploratorio completo y producir las primeras visualizaciones científicas que orientarán las decisiones analíticas de las semanas siguientes.

Acciones:

- Ingresar al entorno virtual del curso y descargar el Anexo 1 – Repositorio Oficial del Entorno. Ingresar al repositorio oficial del entorno y descargar el dataset compartido provisto por el tutor en el repositorio oficial del entorno, junto con su documentación (diccionario de variables, descripción del problema analítico rector y guía de inicio rápido).
- Crear un nuevo Jupyter Notebook e iniciar el análisis exploratorio, documentando cada paso con celdas Markdown que expliquen las decisiones tomadas:
  - Carga e inspección inicial: tipos de variables, tamaño del dataset, estructura (shape), primeras filas (head, describe).
  - Diagnóstico de calidad: valores faltantes (porcentaje por variable), duplicados, inconsistencias, tipos de datos incorrectos.

Documentar las decisiones sobre el tratamiento de cada problema encontrado.

- Estadística descriptiva robusta: medidas de tendencia central (media, mediana, moda), dispersión (desviación estándar, rango intercuartílico — IQR, MAD), forma de las distribuciones (asimetría, curtosis). Usar pandas y scipy.stats.
- Detección de outliers: métodos gráficos (boxplot, violin plot) y analíticos (z-score estandarizado, regla IQR). Documentar qué se hará con los outliers detectados y justificar la decisión.
- Visualización científica: histogramas y densidades (distribución de cada variable clave), scatter plots bivariados, heatmap de correlaciones (Pearson/Spearman), pairplot de las variables de interés. Usar matplotlib y seaborn. Todas las figuras deben tener título, etiquetas de ejes y leyenda.

Indicaciones:

Todo el código debe estar documentado con comentarios que expliquen el razonamiento analítico. El notebook debe ser reproducible desde el inicio: ejecutarse de principio a fin sin intervención manual y producir exactamente los mismos resultados. La Semana 5 no tiene entregable formal, pero el notebook exploratorio es el insumo de todas las semanas siguientes — un análisis exploratorio deficiente compromete la calidad de todo lo que viene después.

Productos esperados:

- Notebook exploratorio en desarrollo (no se entrega formalmente, es insumo para las Semanas 6–8).

## **Semana 6 – Comparar grupos: pruebas de hipótesis y análisis de varianza (Trabajo individual)**

Objetivo:

Formular hipótesis de investigación a partir de los patrones observados en la exploración y ejecutar las pruebas estadísticas apropiadas para comparar grupos, reportando tamaño del efecto e intervalos de confianza como información primaria — no el valor p de manera aislada.

Acciones:

- Formular al menos dos hipótesis de investigación derivadas directamente del análisis exploratorio del dataset. Las hipótesis deben ser relevantes para el dominio de TI del dataset e involucrar comparación entre grupos o condiciones.
- Para comparaciones entre dos grupos, seguir este árbol de decisión:
  - Verificar supuestos: normalidad (prueba de Shapiro-Wilk, Q-Q plot) y homocedasticidad (prueba de Levene). Usar `scipy.stats` y `pingouin`.
  - Si se cumplen los supuestos: t-test independiente o pareado (`scipy.stats.ttest_ind` / `ttest_rel`).
  - Si hay duda sobre homocedasticidad: prueba de Welch (parámetro `equal_var=False`) — más robusta que el t-test estándar.
  - Si no se cumple normalidad: Mann-Whitney U (`scipy.stats.mannwhitneyu`).
- Para comparaciones entre tres o más grupos:
  - ANOVA de un factor si se cumplen supuestos de normalidad y homocedasticidad (`scipy.stats.f_oneway` o `pingouin.anova`).
  - Kruskal-Wallis si no se cumplen los supuestos (`scipy.stats.kruskal`).
  - Si ANOVA es estadísticamente significativo: prueba post-hoc de Tukey HSD para identificar qué pares de grupos difieren (`pingouin.pairwise_tukey`).
- Para cada prueba ejecutada, reportar obligatoriamente:
  - Estadístico de prueba y valor p.
  - Tamaño del efecto: d de Cohen para comparaciones de dos grupos (`pingouin.compute_effsize`),  $\eta^2$  (eta cuadrado) para ANOVA (`pingouin.anova`). Interpretar la magnitud (small, medium, large según los umbrales de Cohen, 1988).
  - Intervalo de confianza al 95%.
  - Interpretación sustantiva: no solo "se rechaza  $H_0$ " sino qué significa el resultado en el contexto del problema de TI del dataset. ¿Qué implica este hallazgo para la investigación?

### Indicaciones:

La idea central de esta semana es que t-test, Welch, Mann-Whitney, ANOVA y Kruskal-Wallis no son "temas estadísticos diferentes" sino herramientas para una misma tarea: comparar grupos. La elección entre ellas depende únicamente de los supuestos de los datos. A nivel doctoral, el tamaño del efecto y los intervalos de confianza son información primaria; el valor p es secundario (Wasserstein & Lazar, 2016). Un

hallazgo estadísticamente significativo con un tamaño del efecto negligible ( $d < 0.20$ ) no es un hallazgo sustantivamente relevante.

Productos esperados:

- Sección de comparación de grupos agregada al notebook en desarrollo.

## **Semana 7 – Modelar relaciones: regresión lineal múltiple (Trabajo individual)**

Objetivo:

Ajustar un modelo de regresión lineal múltiple al dataset, ejecutar un diagnóstico completo de supuestos e interpretar los coeficientes en el contexto sustantivo del problema de TI.

Acciones:

- Identificar una pregunta de investigación del dataset que se pueda abordar mediante un modelo de regresión lineal múltiple (una variable dependiente continua explicada por dos o más predictores).
- Calcular la matriz de correlación (Pearson y/o Spearman según la naturaleza de las variables) e interpretar las relaciones bivariadas como punto de partida para la selección de predictores.

Ajustar el modelo usando statsmodels (no scikit-learn): statsmodels.formula.api.ols produce la salida estadística completa necesaria para un reporte científico (coeficientes, errores estándar, intervalos de confianza, p-values,  $R^2$ ,  $R^2$  ajustado, AIC/BIC). scikit-learn optimiza la predicción pero no proporciona esta información inferencial.

- Ejecutar el diagnóstico completo de supuestos del modelo:
  - Linealidad: gráfico de residuos vs. valores predichos (debe mostrar dispersión aleatoria, sin patrones sistemáticos).
  - Normalidad de los residuos: histograma de residuos, Q-Q plot, prueba de Shapiro-Wilk sobre los residuos.
  - Homocedasticidad: gráfico de residuos vs. valores predichos, prueba de Breusch-Pagan (statsmodels.stats.diagnostic.het\_breuschpagan).
  - Multicolinealidad: Factor de Inflación de la Varianza (VIF) para cada predictor

- (statsmodels.stats.outliers\_influence.variance\_inflation\_factor).  
VIF > 10 es problemático.
- Observaciones influyentes: distancia de Cook para detectar observaciones que afectan desproporcionadamente el modelo.
- Si algún supuesto se viola, documentar la violación y, cuando sea posible, aplicar una corrección justificada (transformación de variables, eliminación de outliers influyentes con fundamentación, uso de errores estándar robustos).
- Interpretar los coeficientes del modelo en el contexto del problema de TI: no solo reportar " $\beta = 0.34$ ,  $p < 0.01$ " sino explicar qué significa ese coeficiente para el fenómeno estudiado.

### Recurso de andamiaje (Semana 7)

Se provee un Jupyter Notebook plantilla de diagnóstico de regresión (diagnostico\_regresion\_plantilla.ipynb) con el esqueleto completo estructurado: celdas de código con los parámetros a completar para VIF (variance\_inflation\_factor), Breusch-Pagan (het\_breuschpagan), distancia de Cook, gráfico Q-Q de residuos y gráfico residuos vs. predichos. Cada celda de código va seguida de una celda Markdown con preguntas de interpretación que el estudiante debe responder. El estudiante completa los parámetros, ejecuta e interpreta — no construye el diagnóstico desde cero.

### Indicaciones:

Esta semana tiene un único foco: dominar la regresión lineal múltiple con profundidad diagnóstica. La regresión es probablemente el método estadístico más utilizado en investigación empírica en TI y en ciencias sociales. Dominar su diagnóstico completo es una competencia doctoral no negociable. El uso obligatorio de statsmodels (en lugar de scikit-learn) es deliberado: statsmodels genera la salida inferencial completa que exigen las revistas académicas.

### Productos esperados:

- Sección de regresión lineal múltiple agregada al notebook en desarrollo.

## **Semana 8 – Extender el modelo: regresión logística + punto de control obligatorio (Trabajo individual + sesión sincrónica)**

### Objetivo:



Ampliar las competencias de modelamiento estadístico aprendiendo la regresión logística binaria como extensión natural del modelo lineal para variables dependientes categóricas. Integrar las secciones de la Parte 1 en un notebook coherente, entregarlo como punto de control para retroalimentación del tutor, y comunicar la técnica avanzada seleccionada para la Parte 2.

#### Acciones:

- Regresión logística binaria:
  - Si el dataset contiene una variable dependiente binaria (por ejemplo: ataque/no ataque, adopta/no adopta, éxito/fracaso), ajustar un modelo de regresión logística binaria usando `statsmodels.formula.api.logit`.
  - Interpretar los coeficientes como odds ratios: para cada predictor, calcular  $\exp(\beta)$  e interpretar su significado sustantivo en el contexto del problema de TI.
  - Evaluar el ajuste del modelo: tabla de clasificación (accuracy, precision, recall), pseudo- $R^2$  (McFadden), AIC/BIC.
  - Si el dataset no contiene una variable binaria natural, dicotomizar justificadamente una variable continua con base en un umbral disciplinario (por ejemplo: severidad alta/baja de un incidente con base en un umbral estándar del dominio). Documentar y justificar la decisión.
- Integración y punto de control obligatorio:
  - Revisar y depurar el notebook completo de la Parte 1, verificando que:
    - Se ejecuta de principio a fin sin errores (reproducibilidad completa).
    - Cada celda de código tiene documentación en Markdown que explica la decisión analítica.
    - Las celdas de texto narran el análisis como una historia coherente con el problema analítico rector.
    - Las visualizaciones tienen títulos, etiquetas de ejes y leyendas claras.
    - Las tablas de resultados siguen el formato requerido para el reporte científico final (APA/IEEE).
  - Redactar el resumen ejecutivo de la Parte 1 (máximo 800 palabras) al inicio del notebook: problema abordado, principales hallazgos exploratorios, resultados de comparación de grupos con tamaños del efecto, resultados de los modelos de regresión con interpretación sustantiva.



Entregar el notebook de la Parte 1 en el foro correspondiente al ciclo el entorno virtual. Esta entrega es OBLIGATORIA y es condición para recibir retroalimentación del tutor antes de iniciar la Parte 2. No tiene puntaje independiente — los 200 puntos se asignan al reporte final integrado — pero su no entrega evidencia falta de proceso formativo y se reflejará en la evaluación de la evidencia final.

- Publicar en el foro correspondiente al ciclo del entorno virtual, un resumen de los principales hallazgos de la Parte 1 (máximo 500 palabras). Como todos los estudiantes de la cohorte trabajaron con el mismo dataset, las diferencias en los resultados revelarán decisiones analíticas distintas — estas diferencias son el insumo de la webconferencia de retroalimentación.
- Participar en la webconferencia de retroalimentación colectiva programada por el tutor. En esta sesión se discutirán: los patrones observados en los análisis de la cohorte, las diferencias en las aproximaciones analíticas de los estudiantes, los errores comunes detectados por el tutor en los notebooks entregados, y las mejores prácticas identificadas.
- Comunicar en el foro correspondiente al ciclo la técnica avanzada seleccionada, antes del cierre de la Semana 8, para garantizar diversidad de técnicas en la cohorte y facilitar el code review entre pares.

Productos esperados:

- Notebook de la Parte 1 entregado en el foro correspondiente al ciclo.
- Publicación del resumen de hallazgos en el foro correspondiente al ciclo (máximo 500 palabras).
- Comunicación al tutor y compañeros en el foro correspondiente al ciclo, sobre la técnica seleccionada para la Parte 2.

## **Parte 2 — Profundización Avanzada (Semanas 9–12)**

En esta fase, el doctorando selecciona una técnica del siguiente menú y la aplica al dataset compartido de la cohorte. La selección debe realizarse en función de la pertinencia para su línea de investigación del DTI y debe comunicarse en el foro correspondiente a la actividad, al cierre de la Semana 8.

Menú de técnicas avanzadas (seleccionar exactamente 1):

Opción 1 — Análisis multivariante y SEM (Recomendada para IASC, ADVTD, CRIC):

- Análisis de Componentes Principales (PCA): reducción de dimensionalidad con `scikit-learn` (`sklearn.decomposition.PCA`); interpretación de componentes y varianza explicada; visualización del espacio reducido. Aplicable cuando el dataset tiene muchas variables correlacionadas.
- Análisis Factorial Exploratorio / Confirmatorio (AFE/AFC): identificación de estructuras latentes subyacentes a los datos con `factor_analyzer`; evaluación de índices de ajuste. Especialmente relevante para estudios de adopción tecnológica con instrumentos de escala.
- Modelos de Ecuaciones Estructurales (SEM/PLS): evaluación de relaciones entre constructos latentes con `semopy`; especialmente útil para modelos de aceptación tecnológica (TAM, UTAUT). Índices de ajuste: CFI, RMSEA, SRMR.

Opción 2 — Series temporales (Recomendada para IoT, CRIC):

- Descomposición de series temporales: identificación de componentes de tendencia, estacionalidad y residuo con `statsmodels.tsa.seasonal_decompose`.
- Análisis de estacionariedad: prueba de Dickey-Fuller aumentada (ADF) con `statsmodels.tsa.stattools.adfuller`; diferenciación si es necesario.
- Ajuste y evaluación de modelos ARIMA: selección de órdenes  $p$ ,  $d$ ,  $q$ ; ajuste con `statsmodels.tsa.arima.model.ARIMA`; evaluación de capacidad predictiva (RMSE, MAE en conjunto de prueba); gráficos de diagnóstico de residuos. Aplicable cuando el dataset tiene componente temporal (logs, tráfico de red, métricas IoT).

Opción 3 — Inferencia bayesiana (Recomendada para CRIC, IASC):

- Replanteamiento bayesiano: tomar al menos una de las hipótesis abordadas en la Parte 1 y reformularla en términos bayesianos usando PyMC.
- Especificación del modelo: definición de priors justificados con base en conocimiento disciplinar, definición de la verosimilitud, construcción del modelo en PyMC.
- Estimación e inferencia: estimación por MCMC (No-U-Turn Sampler); diagnóstico de convergencia ( $R$ -hat, trace plots) con `arviz`; reporte de posteriori, intervalos de mayor densidad (HDI) y factores de Bayes.

- Comparación con el análisis frecuentista: discusión explícita de qué información adicional aporta el enfoque bayesiano frente a los resultados frecuentistas de la Parte 1 (Kruschke, 2015).

#### Opción 4 — Evaluación estadística de modelos de ML (Recomendada para IASC, ADVTD):

- Entrenamiento de modelos: entrenar al menos tres clasificadores o regresores con scikit-learn (por ejemplo: Random Forest, SVM, Gradient Boosting, Logistic Regression, KNN). Justificar la selección de modelos.
- Evaluación con validación cruzada anidada: usar `sklearn.model_selection.cross_val_score` y `RepeatedKFold` para estimaciones robustas del rendimiento. Reportar media y desviación estándar de las métricas.
- Comparación estadística rigurosa entre modelos: prueba de McNemar para comparaciones pareadas (`mlxtend.evaluate.mcnemar`), prueba de Demšar para comparaciones múltiples (Demšar, 2006). No comparar solo los promedios de accuracy — reportar intervalos de confianza sobre las diferencias de rendimiento (Benavoli et al., 2017).
- Interpretación como investigación: las métricas de evaluación (accuracy, F1-score, AUC-ROC, RMSE) son variables dependientes de la investigación — reportarlas e interpretarlas como tal.

### **Semanas 9–10 – Aplicación de la técnica avanzada seleccionada (Trabajo individual)**

#### Objetivo:

Aplicar la técnica avanzada seleccionada al dataset de la cohorte, produciendo análisis documentados y reproducibles que integren los aprendizajes con la retroalimentación recibida sobre la Parte 1.

#### Acciones:

- Incorporar la retroalimentación del tutor sobre la Parte 1 antes de continuar. Si el tutor señaló errores metodológicos o de implementación, corregirlos en el notebook.
- Para la técnica seleccionada:
  - Justificar por qué esa técnica es pertinente para los datos y el problema analítico rector — ¿qué pregunta responde que la Parte 1 no podía responder?

- Ejecutar la técnica en Python con la librería correspondiente (ver menú de la Parte 2). Documentar cada decisión metodológica: ¿por qué esos hiperparámetros? ¿por qué esa especificación del modelo? ¿qué alternativas se consideraron y por qué se descartaron?
- Interpretar los resultados en el contexto del problema de TI del dataset — no presentar simplemente las salidas numéricas, sino razonar sobre su significado para el fenómeno investigado.
- Evaluar las limitaciones de la técnica aplicada: ¿qué supuestos requiere que no se cumplen perfectamente? ¿qué no puede responder esta técnica?

Recurso de andamiaje (Semanas 9–10): utilizar el notebook de ejemplo trabajado del tutor para comprender el proceso analítico completo de la técnica elegida sobre datos similares. Luego adaptar la estructura al dataset de la cohorte, completando el análisis con el problema analítico rector. No copiar el notebook del ejemplo — adaptarlo con comprensión genuina de cada decisión.

Indicaciones:

La aplicación de la técnica avanzada debe ser genuina y analíticamente fundamentada — no basta con ejecutar una función y copiar la salida. Se espera que el doctorando demuestre comprensión conceptual de la técnica, justifique sus decisiones de implementación y dialogue críticamente con los resultados. Si una técnica no produce resultados interpretables con el dataset (por ejemplo, si el dataset no tiene suficiente componente temporal para series temporales), el estudiante debe documentar ese hallazgo con rigor y explorar una alternativa del menú.

Productos esperados:

- Secciones de técnicas avanzadas agregadas al notebook en desarrollo.

## **Semana 11 – Reproducibilidad, publicación FAIR y code review entre pares (Trabajo individual + colaborativo)**

Objetivo:

Garantizar la reproducibilidad científica del análisis completo, publicar el código bajo principios FAIR y ejecutar la revisión científica entre pares del notebook de un compañero.

#### Acciones:

- Preparación del notebook para publicación FAIR:
  - Completar la documentación del notebook final, asegurando que integra de forma coherente las Partes 1 y 2 en una narrativa analítica continua. El notebook completo debe tener un resumen ejecutivo al inicio (máximo 800 palabras) y celdas Markdown que articulen el análisis como una historia científica.
  - Verificar reproducibilidad completa: ejecutar el notebook en un entorno limpio (kernel reiniciado, sin variables en memoria previa) de principio a fin sin errores. Fijar las versiones de las librerías usadas (requirements.txt o conda environment.yml).
  - Preparar el notebook para publicación FAIR:
    - Crear un archivo README.md con: descripción del análisis, dataset utilizado (con referencia completa), instrucciones de ejecución paso a paso, lista de dependencias y versiones.
    - Agregar metadatos al notebook: autor, fecha de análisis, dataset, versión del notebook, licencia del código (recomendada: MIT o CC BY 4.0).
    - Publicar el notebook en un repositorio público (GitHub o GitLab), organizando el repositorio con carpeta data/ (o instrucciones para obtener los datos), carpeta notebooks/, y el README.md en la raíz.
    - Opcionalmente, registrar el repositorio en Zenodo u OSF para obtener un DOI permanente que pueda citarse en el reporte científico.
- Code review entre pares (actividad colaborativa — Semana 11): Cada doctorando revisa el Jupyter Notebook de las Partes 1 y 2 de un compañero. Esta actividad replica el proceso de revisión por pares de las revistas académicas y constituye evidencia colaborativa del ciclo.  
La revisión evalúa:
  - Reproducibilidad: ¿el notebook se ejecuta de principio a fin sin errores en un entorno limpio?
  - Documentación: ¿las decisiones analíticas están justificadas en las celdas Markdown? ¿es posible entender el análisis sin ejecutar el código?

- Corrección estadística — Parte 1: ¿se verificaron los supuestos antes de aplicar cada prueba? ¿se reportaron tamaños del efecto e intervalos de confianza? ¿la interpretación de los resultados es correcta?
- Calidad de la Parte 2: ¿la selección de técnicas avanzadas está justificada? ¿la implementación es correcta? ¿la interpretación es substantiva?
- Reproducibilidad FAIR: ¿el README es suficientemente claro para que alguien externo reproduzca el análisis? ¿el repositorio está organizado correctamente?

El revisor entrega un reporte de code review (máximo 1 página) al compañero revisado y al tutor, con: (a) confirmación de reproducibilidad, (b) fortalezas identificadas en el análisis, (c) observaciones específicas y sugerencias de mejora. El reporte de code review debe ser constructivo y técnicamente fundamentado.

## **Semana 12 – Reporte científico de resultados (Trabajo individual):**

Objetivo:

Redactar el reporte científico de resultados que comunica de forma académica formal los hallazgos del análisis de Partes 1 y 2.

El reporte científico de resultados se entrega en formato paper (APA 7.<sup>a</sup> edición o IEEE, según preferencia del estudiante), que acompaña al notebook como la comunicación académica formal del análisis. Este reporte NO es una copia del notebook: es un documento formal estructurado que narra los hallazgos de forma argumentada, con tablas y figuras seleccionadas (no todas las salidas del notebook).

Productos esperados:

- Reporte científico de resultados (entrega formal, 8–10 páginas), incluyendo párrafo de implicaciones para la tesis en la Discusión.
- Jupyter Notebook reproducible (.ipynb) con el análisis completo de las Partes 1 y 2 (adjunto a la entrega formal).
- Enlace al repositorio con el código publicado bajo principios FAIR (GitHub/GitLab + Zenodo/OSF con DOI, opcional).
- Reporte de code review del notebook de un compañero (máximo 1 página, adjunto a la entrega formal).



### **3. Lineamientos para la elaboración de las evidencias de aprendizaje a entregar.**

Las evidencias de aprendizaje son las acciones, productos o procesos observables que se realizan y/o entregan para manifestar las capacidades, competencias, habilidades, aptitudes y actitudes adquiridas, y que, a su vez, servirán al tutor para verificar y evaluar su desempeño.

Las evidencias a desarrollar individualmente son:

- Reporte científico de resultados (8–10 páginas, formato paper APA 7.<sup>a</sup> edición o IEEE). El reporte debe contener las siguientes secciones, en este orden:
  - Introducción (1 página): Presentación del problema de TI abordado por el dataset, objetivos del análisis, y preguntas o hipótesis formuladas.
  - Metodología (1–2 páginas): Descripción del dataset, procedimiento de limpieza, justificación de las pruebas de comparación de grupos con base en los supuestos verificados, justificación del modelo de regresión, y justificación de la técnica avanzada de la Parte 2 seleccionada del menú.
  - Resultados — Parte 1: Análisis fundamental (2–3 páginas): Hallazgos del análisis exploratorio (con figuras seleccionadas), resultados de la comparación de grupos (con tamaño del efecto e intervalos de confianza), resultados del modelo de regresión con diagnóstico de supuestos e interpretación de coeficientes.
  - Resultados — Parte 2: Técnica avanzada (2 páginas): Resultados de la técnica avanzada seleccionada, con justificación de su pertinencia para el dataset, interpretación en el contexto del problema de TI y discusión de sus limitaciones.
  - Discusión y conclusiones — incluyendo implicaciones para la tesis (1–2 páginas): Síntesis de hallazgos principales, limitaciones del análisis reconocidas explícitamente, y un párrafo obligatorio de implicaciones para la tesis doctoral: qué aprendió de este análisis y cómo los métodos usados se relacionan con los que planea emplear en su propia investigación.
  - Referencias: Todas las fuentes citadas, en formato APA 7.<sup>a</sup> edición (o IEEE si se optó por ese formato).
- Jupyter Notebook reproducible (.ipynb): El notebook debe contener todo el código del análisis (Partes 1 y 2 completas), documentado y ejecutable de principio a fin sin intervención manual. Debe incluir: un resumen ejecutivo al inicio (máximo 800 palabras), celdas



Markdown que narren el análisis como una historia coherente, visualizaciones con títulos y etiquetas claras, y metadatos al inicio del notebook (autor, fecha, dataset, licencia). Se adjunta como archivo .ipynb a la entrega formal en el entorno virtual.

- Enlace al repositorio con publicación FAIR: Enlace a un repositorio público (GitHub o GitLab) que contenga el notebook final, el README.md con instrucciones de ejecución, las dependencias del entorno y los metadatos del análisis. Opcionalmente, registro en Zenodo u OSF para obtener un DOI citable. La publicación del código bajo principios FAIR es parte constitutiva de la práctica de replicabilidad científica del entorno.

Las evidencias a desarrollar colaborativamente son:

- Participación en el foro de resultados intermedios del entorno: publicación del resumen de hallazgos de la Parte 1 (Semana 8, máximo 500 palabras).
- Code review entre pares: reporte de revisión (máximo 1 página) del notebook de Partes 1 y 2 de un compañero asignado, evaluando reproducibilidad, documentación y corrección estadística (Semana 11). Se entrega adjunto al reporte final de la Semana 12.

Nota: Los foros de discusión en entornos doctorales de la UNAD son para retroalimentar entre pares y con el tutor, conforme a los Lineamientos de Estructura Microcurricular para Entornos Doctorales (VIACI, 2025). No son evaluativos de forma independiente. El punto de control de la Semana 8 es obligatorio pero no tiene puntaje independiente: los 200 puntos del ciclo se asignan al reporte final de la Semana 12, el notebook, el code review y el enlace al repositorio FAIR.

**Para su desarrollo y entrega tenga en cuenta las siguientes orientaciones:**

- El reporte científico es de elaboración estrictamente individual. No se aceptan reportes grupales.
- El conjunto de evidencias (reporte + notebook + enlace repositorio + code review) debe entregarse en el recurso de evaluación

habilitado en el entorno virtual antes de la fecha límite de la Semana 12.

- El punto de control de la Semana 8 (entrega del notebook de Parte 1) es obligatorio. Su no entrega evidencia falta de proceso formativo y se reflejará en la evaluación final del ciclo.
- El Jupyter Notebook debe ser completamente reproducible: se ejecuta de principio a fin sin intervención manual y produce los mismos resultados. Fijar las versiones de las librerías usadas con requirements.txt o environment.yml.
- El reporte científico NO es una copia del notebook. El notebook es la evidencia reproducible; el reporte es la comunicación académica formal. El reporte selecciona y argumenta — no lista todas las salidas.
- Todos los productos escritos deben cumplir con las normas de ortografía y las condiciones de presentación definidas por el tutor.
- El producto debe cumplir con las normas APA (7.ª edición) o IEEE para el uso y formato de referencias.
- Cumpla con las normas de referenciación y evite el plagio académico. Puede apoyarse revisando sus productos escritos mediante la herramienta Turnitin disponible en el campus virtual.
- El uso de herramientas de Inteligencia Artificial (IA) en la elaboración del reporte y el notebook debe ser ético y responsable. En caso de utilizarse, debe declararse explícitamente al inicio del reporte en qué aspectos se empleó y de qué manera.
- El párrafo de implicaciones para la tesis doctoral incluido en la Discusión del reporte es el insumo directo del Protocolo Metodológico del Ciclo 3.

#### **4. Situaciones de orden académico.**

Considere que en el acuerdo 029 del 13 de diciembre de 2013, artículo 99, se considera como faltas que atentan contra el orden académico, entre otras, las siguientes: literal e) “El plagiar, es decir, presentar como de su propia autoría la totalidad o parte de una obra, trabajo, documento o invención realizado por otra persona. Implica también el uso de citas o referencias falsas, o proponer citas donde no haya coincidencia entre ella y la referencia” y literal f) “El reproducir, o copiar con fines de lucro, materiales educativos o resultados de productos de investigación, que cuentan con derechos intelectuales reservados para la Universidad” Las sanciones académicas a las que se enfrentará el estudiante son las siguientes:

- a) En los casos de fraude académico demostrado en el trabajo académico o evaluación respectiva, la calificación que se impondrá

será de cero puntos sin perjuicio de la sanción disciplinaria correspondiente.

- b)** En los casos relacionados con plagio demostrado en el trabajo académico cualquiera sea su naturaleza, la calificación que se impondrá será de cero puntos, sin perjuicio de la sanción disciplinaria correspondiente.